

פרויקט גמר מחקרי 2022

הנדסה תעשייה וניהול אוניברסיטת אריאל

Modeling Human Brain Activity

In Secretary Problem

מנחה אקדמי:

ד"ר ינון צוקרמן

סטודנטים:

נועם ישי: 205555022

חן סימון: 208162990

תוכן העניינים

1	מבוא	3
1.1	בעיית המזכירה	4
1.2	ELECTROENCEPHALOGRAM - EEG	9
1.3	מטרת המחקר	11
2	שיטה	12
2.1	כלים וחומרים	12
2.2	תוקף ומהימנות כלי המחקר	18
2.3	מהלך הניסוי	19
3	ניקוי רעשים מהפלט	21
3.1	מקורות רעש ב-EEG	21
3.2	שלבים לניקוי הרעשים מהפלט	22
4	שיטת ניתוח פלט ה-EEG	29
5	תוצאות	31
6	הנחות ומגבלות המחקר	34
7	דיון ומסקנות	35
8	דיון נועם	36
9	דיון חן	37
10	נספחים	38
10.1	נספח א' - טבלת הצעות מחיר	38
10.2	נספח ב' - תמונת גולמית של גלי ה-EEG	39
10.3	קטע הקוד הרשום ב-PYTHON	40
11	מקורות	44

1. מבוא

"בעיית המזכירה" עוסקת במעסיק המחפש מזכירה כאשר הוא מפרסם מודעה בעיתון שעליה עונות N מועמדות אשר מגיעות להתראיין לעבודה. ברצונו של המעסיק לשכור את המועמדת הטובה ביותר מבין אלו שהופיעו. את המועמדות הוא מראיין זו אחר זו בסדר אקראי, ואחרי כל ראיון, עליו להחליט אם להציע למועמדת הנוכחית את המשרה או לעבור למועמדת הבאה. בעת שהוא מחליט, הוא יכול לדרג את המועמדות שראה עד עתה, אך אין ביכולתו להשוות אותן למועמדות שטרם ראיין. אם יחליט המעסיק לא להציע למועמדת הנוכחית את המשרה, היא תעבור לעבוד במקום אחר ולכן לא תסכים לקבל את המשרה גם אם המעסיק יחזור בו ויציע לה את המשרה לאחר שראיין עוד מועמדות. לכן, מיד אחרי ראיון שקיים עם כל מועמדת, חייב המעסיק להתחייב להעסיקה או לוותר על שירותיה. תנאי הבעיה קובעים שאם לא נשכרה אף מועמדת לפני המועמדת האחרונה, המעסיק יהיה חייבת לשכור אותה. בגרסה אחרת של הבעיה מסופר על רווק שחבריו סידרו לו אוסף מועמדות שיוכל לשאת לאישה, ולכן לפעמים מכנים בעיה זו "בעיית הנישואים" או "בעיית הרווק".

השאלה שהבעיה עוסקת בה היא כיצד אפשר להגדיל את הסיכוי לשכור את המועמדת הטובה ביותר (או להציע נישואין לאישה הטובה ביותר), ומה ההסתברות שהמועמדת הטובה ביותר תיבחר תחת האסטרטגיה האופטימלית.

ע"י חישוב מתמטי הסתברתי ניתן לחשב את הנקודה האופטימלית שלאחריה יהיו בידי המנהל מספיק תצפיות על מנת לקבל החלטה מי המזכירה הטובה ביותר [1].

מטרת המחקר לחפש האם ישנה פעילות חשמלית מוחית הניתנת לזיהוי באותות ה-EEG במהלך משחק הכפוף לתנאי בעיית המזכירה המעיד על בשלות האדם לקבל החלטה, כלומר, האם נראו מספיק תצפיות וקיימת בשלות לבחירת המועמדת.

נושא זה עדיין לא נחקר וזה מחקר ראשון מסוגו הבוחן שילוב של בשלות בקבלת החלטות תחת בעיית המזכירה ע"י שימוש בניתוח התנהגות המוח (EEG).

1.1. בעיית המזכירה

1.1.1. הצגת בעיית המזכירה הקלאסית

מאמר [1] מציג המחבר (Thomas Ferguson) את ההיסטוריה והמקור של בעיית המזכירה, המחבר סוקר את הדרך לפתרון הבעיה ע"י כלל עצירה (אסטרטגית עצירה) שבה ניתן להבטיח את הבחירה המיטבית נוכח המציאות.

ע"י חישובים מתמטיים והסתברותיים נמצא כי על המנהל לראיין ולדרג כ-37% מכלל המועמדות, לאחר מכן על המנהל להמשיך ולראיין את שאר המועמדות ולבחור את המזכירה הראשונה שהדירוג שלה גדול או שווה לדירוג הגבוה ביותר שניתן ב-37% מהמזכירות הראשונות [1,2].

הפתרון האופטימלי המתאים לאסטרטגיה המוצעת במאמר נכון לבעיית המזכירה הקלאסית המבוססת על ההנחות הבאות:

1. יש משרת מזכירה אחת פנויה.
 2. מספר המועמדות n ידוע למנהל מראש.
 3. המועמדות מרואיינות בסדר רנדומלי, אין חשיבות לסדר.
 4. קיימת הנחה שמנהל יכול לדרג את כל המזכירות מהטובה ביותר עד הגרועה ביותר, וההחלטה לדחות או לקבל את המזכירה באותו ראיון מבוסס על דירוג המזכירות שראה עד כה.
 5. מזכירה שנדחתה לא תוכל להיבחר לעבודה.
 6. המנהל שואף לבחור את המזכירה הטובה ביותר מבין המועמדות.
- המודל המתמטי האסטרטגי:** נבחר במועמדות r כלומר נדחה $r-1$ מועמדות מקדימות. בעבור $r=1$ הסיכוי לבחור את המועמדת הטובה ביותר הוא $1/n$ ועבור $r>1$:

$$\Phi_n(r) = \sum_{j=r}^n P(jth \text{ applicant is the best and you select it}) =$$

$$\sum_{j=r}^n \left(\frac{1}{n}\right) \left(\frac{r-1}{j-1}\right) = \frac{r-1}{n} \sum_{j=r}^n \frac{1}{j-1}$$

ה- r האופטימלי הוא זה שממקסם את הסתברות הבחירה במועמדת הטובה ביותר. בשביל מספר גדול של מועמדות (n) נגדיר את x כגבול מספר המועמדת ביחס לכל המועמדות (r/n), נגדיר t כגבול מיקום המועמדת הטובה ביותר ביחס למועמדת הנבחרת (נשאף שיהיה שווה ל-1) והנגזרת של t , כלומר, dt יהיה שווה ל- $1/n$, ונשתמש בסכום ריימן (Riemann sum) על מנת להעביר את הסדרה לאינטגרל:

$$\Phi_n(r) = \frac{r-1}{n} \sum_{j=r}^n \left(\frac{n}{j-1}\right) \left(\frac{1}{n}\right) = x \int_x^1 \frac{1}{t} dt = -x \ln(x)$$

על מנת למצוא פתרון אופטימלי נגזור ונשווה ל-0 ונקבל ש: $x \rightarrow 1/e$, כלומר, כמות המועמדות שנדרש לראות ביחס לכמות המועמדות על מנת לקבל הערכה ודירוג לגבי המזכירות הוא בערך 37% [1].

1.1.2. הצגת בעיות דומות מהעבר

הפעם הראשונה שהבעיה הוזכרה בכתב הייתה בטור של מרטין גרדנר [1] כפי שגרדנר ניסח את הבעיה, היא אינה זהה במדויק לבעיית המזכירה הקלאסית, ותוארה "כמשחק הגוגל" בצורה הבאה: אדם כותב מספרים שונים על N פיסות נייר המספרים עשויים לנוע בין שברים קטנים של 1 למספר בגודל של גוגל (1 ואחריו 100 אפסים), זורק את כולן לכובע, ושולף אותן בסדר אקראי. בהצגתו שאל כיצד ניתן להגדיל את ההסתברות שנבחר במספר הגבוה ביותר מבין כל הפתקים. לכאורה, תיאור זה נראה זהה לבעיית המזכירה. אך ישנו הבדל חשוב: בבעיה שהוצגה, ניתן לראות את הערך של המספרים שכתובים על הפתקים, הבדל זה חשוב, משום שייתכן שנוכל להיעזר בערכי המספרים עצמם לשפר את הסיכויים שנבחר נכון (אין נמוך מ-0 ואין גדול ממספר גוגל) בשונה מבעיית המזכירה הקלאסית שהדירוג של המזכירה אינו ידוע מראש הדבר בא לידי ביטוי בצורה שנבחרו המספרים. למשל, אם אנחנו יודעים שהוא כתב את המספרים השלמים מ-1 עד N , נוכל בקלות להבטיח שנבחר במספר הגבוה ביותר על ידי זה שנחכה עד המספר N ואז נפסיק. גם במצב בו אנחנו יודעים שהאדם בחר את המספרים באופן אקראי ובלתי תלוי מהתפלגות קבועה, עדיין ניתן להשתמש בערכים שנראה לשפר את ההסתברות שנבחר במספר הגבוה ביותר.

במחקר [3] אימצו החוקרים את משחק האולטימטום כדי לדמות את קבלת החלטות בפועל בצורה טובה על מנת לנסות לחזות את החלטת הנבדק, המשחק משקף שיקול הוגנות בחלוקת כסף ומתבסס על החלטת עצירה של הנחקר המטיבה עימו, הנחקר התבקש להחליט האם לקבל את הצעת המציע (המחשב). אם הנחקר קיבל את ההצעה, שני השחקנים (המשיב והמציע) מקבלים את הכסף שמסר המציע, אחרת לא ירוויח כלום. בניסוי, הסכום היה פיצולים של $\text{¥} 10$. הניסוי כלל שלוש קטגוריות של תנאים: ההצעות הוגנות ($\text{¥} 5 : \text{¥} 5$) וההצעות הלא הוגנות, שכללו ($\text{¥} 1 : \text{¥} 9$) ו ($\text{¥} 3 : \text{¥} 7$). הנבדקים קיבלו 90 הצעות שנבחרו באקראי על ידי המחשב, עם 30 ניסויים עבור כל אחד משלושת התנאים.

1.1.3. הצגת ניסויים התנהגותיים הקשורים בבעיית המזכירה

תוצאות מחקר [6] מצביעות על כך שנבדקים המתמודדים עם בעיות כמו בעיית המזכירה נוטים לסיים את החיפוש שלהם מוקדם מדי ביחס למדיניות האופטימלית ועשויים להתנהג באופן תת-אופטימלי, אנשים עשויים לקבל החלטות טרייד-אוף (trade-off) גרועות ולהעדיף מועמדים שהם "בינוניים" לעומת מועמדים "מצוינים" וזה מתוך החשיבה כי תמיד יוכלו לקבל גם מועמד שהוא "גרוע", גם כאשר הפרס הצפוי עבור המועמד הבא הוא גדול יותר, הנבדקים עושים פשרות ומתנהגים באופן העולה בקנה אחד עם צורה של אופטימיזציה (אם כי ההתנהגות עדיין תת-אופטימלית ביחס למדיניות האופטימלית). דפוס התוצאות מצביע על כך שהנבדקים אינם עוקבים אחר איזה תאוריה היוריסטית פשוטה בה הם משתמשים כדי לקבל את החלטותיהם. נראה כי המדיניות שלהם הייתה מסובכת יותר, תוך הסתמכות על פרופיל הדירוג היחסיים הספציפיים של המועמדים שנצפו. מבלי להזדקק לכללי החלטה מורכבים יותר.

במחקר [10] החוקר מזהה מספר גורמים התורמים באופן משמעותי להחלטות החיפוש הרצופות של האדם תחת בעיית המזכירה הממוסגרת כהקשר למכירת בית והם כוללים את עלויות החיפוש, ההקשרים (מה אני מחפש), שנאת החרטה והתמריצים.

החוקר מצא שאם כל חיפוש נוסף היה כרוך בעיכוב זמן שהוכרז מראש, אנשים קיצרו את החיפוש במטרה לקצר זמנים וקיים רצון לסיים את החיפוש בשביל לחסוך עלויות (זמן). בנוסף מצא החוקר שקיימת השפעה להקשר החיפוש על מידת הרצון של הנבדק להצליח בניסוי לדוגמא: הצעות מחיר למכירת בית, אם היה לנבדק הקשר של מה היא מטרת החיפוש שלו (מחיר מקסימלי) הוא היה מחפש בצורה אופטימלית יותר מאשר ללא הקשר, גם ללא מידע על הבית.

בנוסף החוקר מצא ראיות המצביעות על כך שסלידה מחרטה הייתה סיבה להטיית העצירה המוקדמת "הפחד מכישלון" עודד את הנבדקים לקחת הצעות סבירות. בניסוי הרביעי בחן החוקר את קבלת ההחלטות הקבוצתית ומצא שקבוצות בחרו במחירים

פחות אופטימיים מהביצועים המצטברים של היחיד. בניסוי החמישי בחן החוקר את ההשפעה של תמריצים רק עבור מציאת המחיר האופטימלי ומצאת שאנשים אכן קיבלו החלטות אופטימליות יותר כאשר ידעו שיקבלו שכר רק עבור מציאת ההצעה הטובה ביותר. הממצאים מצביעים על כך שכאשר אנו מקבלים החלטות חיפוש עוקבות בחיים, חיפוש מתיש ובחינה של כל ההצעות לעולם אינו מביא לפתרון האופטימלי, לעולם לא ניתן להחזיר את הזמן המושקע, וגם לא ניתן להחזיר את ההצעה שנדחתה. ההקשר של מה שאנחנו מחפשים ואיסוף מידע לפני קבלת החלטות אכן מוביל לתוצאות טובות יותר. הסתפקות בהצעות שאינן הטובות ביותר יכולה לחסוך זמן ומאמץ, והרווחים לא יהיו שונים בהרבה מאשר כאשר מכוונים רק לטוב ביותר.

בנוסף במחקר [11] מסביר החוקר שהקשר הניסוי הינו גורם אשר משפיע בצורה ישירה על מידת ההצלחה בניסוי "הקשר משמעותי יכול לשפר את ההבנה של הסביבה ולהפחית את הבלבול בקרב המשתתפים, במיוחד כאשר משימה דורשת חשיבה מתוככמת, ומכאן עשויה להניב תגובות באיכות טובה יותר" המחקר מסביר על החשיבות של ההקשר (ההקשר של הפעולה שהנבדק עושה אל מול המציאות במקרה שלנו הצעות מחיר לדירה) בניסויים מקרים כדי לשלוט בניסוי ולתת משמעות לניסוי, צריך לבחור הקשר כדי לבטא את מטרות המחקר בצורה טובה ולאפשר כמה שיותר שליטה על איך שהשחקן תופס את הניסוי.

1.1.4. מחקר כמותי המהווה מודל לניסוי המחקר

מחקר [2] יהיה מחקר מודל עבור הניסוי שלנו. על פי המחקר בוצע ניסוי מבוסס בעיית המזכירה כאשר מטרת המחקר הייתה לנתח מצבים נפשיים של אנשים תוך עיסוק בתהליכים קוגניטיביים במהלך קבלת החלטות במהלכו של הניסוי במחקר כל משתתף נדרש למכור בית מסוים בכל סיבוב והוא זוכה בגין המכירה לתמריץ כספי לפי שלושה סוגי תמריצים: בסיס עמלות, הטוב ביותר בלבד ועמלה קבועה. חשוב לציין שהניסוי במחקר מקיים את כל האילוצים של בעיית המזכירה. כדי לתת תוקף גבוה למחקר שלנו

לקחנו את מבנה המחקר המוצג במאמר [2] כמודל עבור הניסוי שלנו כאשר הדבר המרכזי שהוספנו היה החיבור ל-EEG. מהניסוי נלקח: טבלת המחירים (נספח א') כאשר השינוי המהותי יהיה להכפיל ב-10 את הערכים בכל עמודה שנייה. כמות המשחקים הופחתה מ-10 משחקים למשתתף (10 בתיים למכור) כמוצג במחקר ל-6 משחקים בניסוי שלנו ונוספו על זה עוד שני משחקי דמה כתרגול לפני הניסוי המלא. בדומה לניסוי במחקר גם אנחנו הענקנו תמריצים כספיים, חולקו סכומי כסף בין 100-150 למשתתף, כאשר הובטח למשתתף שבעבור תוצאה טובה הוא יזכה לכל הסכום (ש150), בפועל סכום הכסף היה מקרי ללא קשר לבחירותיו.

1.2 Electroencephalogram - EEG

EEG הוא מכשיר המשמש לרישום הפעילות החשמלית המוחית. הקסדה נחבשת על ראש הנבדק התומכת ב-16 אלקטרודות המובנות על הקסדה. הקסדה מחוברת למגבר שדר ובעזרת תוכנת מחשב, מוקלט המידע מכל האלקטרודות אל מחשב ה-EEG. על מנת לקבל אותות חשמליים מהקרקפת נדרש לשמור על סף התנגדות של $5\text{ K}\Omega$ וזאת נעשה ע"י ג'ל הגורם להפחתת ההתנגדות. דפוסים המתקבלים הם גלי מוח, והם מאפיינים את הפעילות החשמלית המוחית באזור מסוים [4]. הגלים נמדדו במיקרו וולט (μV) [5].




Figure 2: פריסת האלקטרודות על גבי הראש



Figure 1: דוגמה לקסדת EEG

1.2.1. פלט הבדיקה

המשתנים התלויים בניסוי הם גלי המוח המתווכים מקרקפת הנבדק אשר מהווים את המשתנה התלוי, שהוא תוצאה של המשתנה הבלתי תלוי (קבלת ההחלטה).

Delta - בולט בדרך כלל אצל מבוגרים בחלק הקידמי של הקרקפת בולט במהלך פעילות הדורשת תשומת לב מתמשכת. תדר של 3 Hz או פחות. נטייה למשרעת גבוהה והגלים האיטיים ביותר. מאופיין בחלק הקידמי של הקרקפת: FIRDA - Frontal Intermittent Rhythmic Delta.

Theta - גלים אלו קשורים לעיכוב של תגובות מעוררות (מצאו כי טווח זה מופיע באופן בולט במצבים בהם אדם מנסה באופן פעיל להדחיק תגובה או פעולה). מאופיין בתדר של בין 7.5-3.5 Hz של פעילות מוחית איטית. לא נורמלי אצל מבוגרים כאשר הם ערים.

Alpha - מתרחשים בזמן מנוחה בעיניים עצומות. הם נעלמים במהלך השינה ונעלמים כאשר יש ריכוז במשימה מסוימת. מאופיין בתדר בין 13-7.5 Hz. בדרך כלל נצפה באזורים האחוריים של הראש. תדר אלפה הוא הקצב העיקרי והנורמלי אצל מבוגרים רגועים.

Beta - לגלים אלו יש קשר ישיר לפעילות המוחית הקשורה ללמידה וליכולת הקוגניטיבית של המוח ברגע נתון. גלי בטא מייצגים עוררות, קשב ולעיתים אפילו חרדה. בטא הוא הקצב שמאפיין פעילות מוחית מהירה (תדר של מעל 14 Hz). נראה בעיקר בצדדי הראש וניכר בעיקר בחלק הקידמי. תדר זה נחשב נורמלי [6].

Gama - טווח זה קשור לפעילות מוחית רשתית בקנה מידה גדול, ופעילות קוגניטיבית כמו זיכרון פעיל, תשומת לב וקיבוץ של תפיסות שונות. קשור גם להפעלת מערכת העצבים הסימפתית.




Figure 3: דוגמאות לגרף התדרים: Alpha, Beta, Delta, Theta

1.3. מטרת המחקר

המחקר בא לבדוק ולחפש האם ניתן לזהות שינוי באותות ה-EEG אשר מבטאות את הפעילות החשמלית המוחית, המעיד על מצב בו מקבל החלטה בשל בהחלטתו ל"בחור מזכירה".

השערות המחקר

- א. קיים הבדל בפעילות המוחית לפני ואחרי זמן הבשלות המוחית לקבל החלטה הניתן לאבחון כההליך לגיבוש החלטה.
- ב. קיים קשר בין הפתרון המתמטי של בעיית המזכירה הקלאסית ($1/e$) אל מול השלב בו המוח בשל לקבל החלטה.
- ג. קיים הבדל בפעילות המוחית בקבלת החלטות תוך הבחנה בין קבלה לדחייה.

שיטה 2.

את המחקר נבצע באמצעות בחינת התמודדות של נחקרים עם "דילמת החלטה" הדומה בתפיסתה לבעיית המזכירה, במהלכה הנחקרים יצטרכו להתמודד עם דילמה בה הם יצטרכו למקסם את הרווח שלהם ע"י קבלת החלטה אשר בעיניהם היא ההחלטה המיטבית אבל לא בהכרח הינה ההחלטה הטובה ביותר.

הנחקרים יצטרכו לגבש החלטה ולהחליט מתי המספר המוצג בפניהם הינו המספר המקסימלי אותו יוכלו לקבל.

2.1 כלים וחומרים

2.1.1 EEG-Electroencephalogram

על מנת לראות את הפעילות החשמלית המוחית השתמשנו בקסדת EEG בעלת 16 ערוצים בתדר דגימה של 512 Hz הממפה את הפעילות החשמלית הנוצרת בתאי העצב בקליפת המוח ומייצרת תרשים של הפעילות המוחית אשר נותנת לנו אינדיקציה על העברת האותות העצביים במוח.

נתוני ה-EEG הוקלטו בעזרת 16 ערוצים, תדר הדגימה הינו 512 Hz כאשר הדגימות הוקלטו בעזרת תוכנת ההקלטה Open Vibe (התנגדות האלקטרודות תשמר מתחת לסף של 5 K Ω לאורך כל הדגימות). הקלטת ה-EEG תהייה במקביל להקלטת המסך המוקרן לנחקר.

2.1.2 Experiment Software

על מנת לאפשר לנבדק להתמודד עם בעיית החלטה הדומה לבעיית המזכירה בנינו אפליקציה המתממשקת עם ה-EEG בה הנבדק צריך להתמודד עם בעיית החלטה הדומה לבעיית המזכירה. כך שעבור כל החלטה של הנבדק יופיע trigger ברצף הזמן של פלט ה-EEG.

במהלך המשחק הנחקר יקבל כמות ידוע מראש של מספרים שערכם אינו ידוע עבורו ובכל מופע של מספר הנחקר יבחר 'yes' או 'no', לקבל או לדחות את ההצעה בהתאמה תוך רצון למיקסום הערך המתקבל, אם דחה את ההצעה לא יוכל לבחור בה שוב ואם קיבל את ההצעה לא יוכל לראות מה הפסיד, במקרה ובו לא בחר הצעה עד סוף המשחק ההצעה האחרון תבחר עבורו באופן אוטומטי.

פלטפורמת המשחק והערכים עבורם הנבדק קיבל החלטה לקוחים מתוך מאמר מחקרי בו חקרו את אותות ה-EEG ביחד עם בעיית המזכירה כדי לנתח מצבים נפשיים של אנשים תוך עיסוק בתהליכים קוגניטיביים במהלך קבלת החלטות. לאורך הניסוי הנחקר יהיה מחובר באלקטרודות לקרקפת הראש והפעילות המוחית שלו תוקלט ותנותח אל מול ערך המספרים המוצגים בפני הנחקר.

אפליקציית המשחק פותחה בשפת תכנות java בסביבת עבודה של Maven. המשחק מתחיל במסך פתיחה בשפה העברית הכולל בתוכו את כלל ההוראות בעבור המשתתף כמתואר באיור 4.

ברוך הבא!

במשחק הבא הינך מוכר דירות המקבל 20 הצעות מחיר עבור הדירה שברשותך, המשימה שלך לבחור את הצעת המחיר הגבוה ביותר שתוכל לקבל לדעתך מבלי לראות את שאר ההצעות העתידיות האפשריות ומבלי האופציה לחזור להצעה שכבר סרבת לקבל אותה. שים לב! הצעה שהחלטת לסרב לה ובחרת לראות את ההצעה הבא הינה הצעה שלא תוכל לבחור בה יותר. אם לאחר שראית את כל ההצעות עדיין לא הגעת להחלטה ההצעה האחרונה תבחר עבורך אוטומטי. -הקש על לחצן ה-"N/M" במקלדת כדי לראות את ההצעה הבאה. -הקש על לחצן ה-"Y/T" במקלדת כדי לבחור בהצעה הנוכחית ולסיים את המשחק. את הבחירה יש לעשות כאשר מופיע ההצעה על המסך. בהצלחה!

לחץ על כל לחצן להתחלה

Figure 4: מסך הפתיחה של המשחק

בין כל הצעה להצעה במסך הוצג צלב לבן על רקע שחור לפרק זמן משתנה הנע בין 200-250 msec בצורה רנדומלית וזאת כדי לאפשר לנבדק איזושהי הבחנה בין הצעה להצעה כמתואר באיור 5.




Figure 5: מסך שחור עליו צלב לבן המופיע לפרק זמן משתנה הנע בין 200-250msec

מחשב ההקלטה של גלי ה-EEG מחובר ביחד עם מחשב הניסוי שעליו הנבדק השתמש באפליקציה ככה שעבור כל בחירה של הנבדק מופיע trigger על צייר הזמן של הגלים המוקלטים במחשב ה-EEG.

לאחר העלמות הצלב הלבן תופיעה הצעת מחיר לזמן לא מוגבל שעבורה הנחקר צריך להחליט האם לקבל או לדחות את ההצעה (Y – קבלה ו- N – דחייה) הצעות המחיר שהוצגו היו כאמור לפי הטבלה בנספח א'.



\$625

Figure 6: מסך הצעת מחיר מתוך המשחק

g.tec.2.1.3

על מנת להעביר את גלי המוח למחשב השתמשנו במחקר במכשור של חברת g.tec. כאשר נדרשנו למספר אמצעים: Amplifier, GammaBox, כבלי רשת ו-GammaGel (להפחתת ההתנגדות החשמלית).
להלן ארכיטקטורה של האמצעים:




Figure 7: ארכיטקטורת האמצעים במעבדה

א. Amplifier - הוא מגבר אותות ביולוגיים בעל ביצועים גבוהים ודיוק גבוה לניתוח ועיבוד של אותות פיזיולוגיים. באמצעותו ניתן לתעד את הפעילות הפיזיולוגית מהמוח, העיניים, הלב, השרירים ועוד - כולל נשימה, תגובת עור גליוני, טמפרטורה ועוד פרמטרים פיזיולוגיים ופיזיים רבים נוספים (במחקר שלנו השתמשנו בו לצורך הגברת אותות ה-EEG המתווכים מקרקפת הראש).



Figure 8: g.tech Amplifier

ב. GammaSys - תוכן לבצע הגדרות ניסיוניות להקלטת EEG/ ECG/ EMG/ EOG מהירות וקלות, תוך שימוש במכסה נוחה המספקת איכות אות גבוהה מאוד. g.GammaSys תוכן לעבוד עם כל מגברי g.tec. הוא כולל סוגים שונים של אלקטרודות אקטיביות ופסיביות המחוברות באמצעות g.GammaBox ל- g.UsbAmp וניתן להרכבה עם ה-g.GammaCap על הראש עבור הקלטות EEG.

ג. GammaGel - גל הנועד להפחית את ההתנגדות החשמלית על מנת שנוכל לראות את גלי המוח בצורה ברורה יותר, הורדה לפחות מ-5K Ω .



Figure 10: Gamma Box המקשר בין המגבר לקסדה



Figure 9: Gamma gel

2.2. תוקף ומהימנות כלי המחקר

1. בין הצעה להצעה הוצג מסך פלוס לפרק זמן משתנה הנע בין 200-250 msec בצורה רנדומלית וזאת על מנת למנוע מצב בו הנבדק מצפה להצעה דבר העלול להשפיע על תוצאות הבדיקה.
2. הניסויים נערכו במעבדת EEG, החדר הוקם כדי לשמור על אותם תנאים סביבתיים לכל המשתתפים. הניסויים נערכו עבור כל משתתף בנפרד ובזמנים שונים במהלך היום.
3. על מנת לייצר מוטיבציה למציאת ההצעה הטובה ביותר הובטח לנחקרים תשלום הנע בין 100-150 ₪ התלוי במידת ההצלחה של הנבדק (הצלחה=מציאת ההצעה הטובה ביותר).
4. בתחילת כל ניסוי נבדק האם קיימת עכבה באותות, שיפור העכבה מתבצע ע"י: מריחת תמיסת מלח נוספת ותיקון חיישנים לפי הצורך כדי להבטיח עכבה מינימלית ואיכות אותות אופטימלית בין כל אלקטרודה לקרקפת של הנבדק.
5. עבור כל נבדק הוקלטו 2 דקות בהם הנבדק צפה במסך ריק והתבקש לנקות את הראש ממחשבות וזאת על מנת לייצר דגימת יחוס לשלב העיבוד המקדים של הנתונים.
6. כל הנבדקים ראו את אותם ההצעות ובאותו הסדר.

2.3. מהלך הניסוי

1. הניסוי התקיים באוניברסיטת אריאל בחדר ייעודי. חדר הניסוי היה ללא כניסה של אור שמש, עם פלורסנט אחד בחדר וללא התערבות של מפעילי הניסוי, המשתתפים בניסוי חתמו על טופס הצהרה מדעת.
2. בכל סיבוב, משתתף יכול לסקור עד 20 הצעות מחיר עבור הבית הנתון. הצעות המחיר הוצגו אחת אחת. לאחר הצגת הצעת מחיר, החליט המשתתף האם לדחות את ההצעה או לקבל אותה. ברגע שהתקבלה ההחלטה, לא היה אפשר לחזור בחזרה. אם המשתתף לא קיבל הצעה לפני ההצעה הסופית (ההצעה ה-20), המשתתף נאלץ לקבל את ההצעה הסופית ללא קשר לשוויה. רצפי הצעת המחיר מוצגים בנספח א'.
3. כדי לאפשר תוקף ומהימנות כל משתתף ראה את אותם ערכים ובאותו הסדר כך שמיקום ההצעה הטובה ביותר נשמר בעבור כל המתמודדים. לפי המחקר מיקום ההצעה האופטימלית נבחר בהתאם לאסטרטגיה הקלאסית כלומר אחרי $1/e$ מהתצפיות.
4. המשתתף עבר תדריך על הניסוי אותו הוא הולך לבצע, בהמשך חובר לקסדת ה-EEG. עם החיבור לקסדה הוא ביצע 4 שלבים:
 - א. הקלטת הפעילות החשמלית של הנבדק למשך 2 דקות במצב שקט מול צלב אדום על רקע אפור.
 - ב. 2 משחקים מקדימים מניסויי מחקרי שבועו במקביל.
 - ג. משחק דמה בעל 2 סיבובים ללא הקלטה, ללא הגבלת זמן.
 - ד. משחק מלא בעל 6 סיבובי משחק כולל הקלטה, ללא הגבלת זמן.

ה. הקלטת הפעילות החשמלית של הנבדק למשך 2 דקות במצב שקט לאחר המשחק.

כל המשתתפים קיבלו הוראות זהות לגבי אופן הפעילות בניסוי. בפני כולם הוצג שתוצאות טובות יניבו תמריץ גדול יותר בטווח בין 100-150 על אף שהמספר נקבע בצורה שרירותית.

המחקר היה חלק מ-3 ניסויים במקביל כך שבתחילת המחקר הם ענו על שאלון לניסוי התנהגותי הקשור למחקר נוסף. הם שיחקו ב-3 אפליקציות בסדר קבוע כאשר השלישית מבניהם היא האפליקציה שלנו. אף משתתף לא ידע על הפרדה בין הניסויים, הוא קיבל את המידע שהוא משתתף בניסוי קוגניטיבי לא פולשני שבא לבדוק את התוצאות של הבחירות שלו.



Figure 11: מעבדת הניסוי באוניברסיטת אריאל בשומרון

3. ניקוי רעשים מהפלט

Preprocessing - העיבוד המקדים של הנתונים בוצע במספר שלבים כאשר כל שלב מתמקד בניקוי מקור רעש אחר והכנת הנתונים לניתוח.

3.1. מקורות רעש ב-EEG

מקורות פיזיולוגיים:

מקורות פיזיולוגיים של רעש כוללים שרירים (במיוחד שרירי פנים וצוואר, המייצרים פוטנציאלים חשמליים בעת התכווצות ומנוחה), העיניים (היוצרות אותות ייחודיים הן במהלך מצמוצים, והן כאשר גלגלי העיניים זזים), פעימות לב (הלב מייצר אותות חשמליים חזקים וייחודיים) ונשימה.

מקורות לא פיזיולוגיים:

מקורות לא פיזיולוגיים כוללים ממצאים הנוצרים כאשר אלקטרודות נעות ביחס לקרקפת, כאשר חוטי האלקטרודות זזים, ורעש אלקטרומגנטי סביבתי. רעש אלקטרומגנטי נוצר על ידי כמעט כל מכשיר המשתמש בחשמל (למעט כמה התקנים המופעלים באמצעות סוללה) או ממקורות חשמל המספקים חשמל בתדר גבוה.

3.2. שליבים לניקוי הרעשים מהפלט

3.2.1. שלב א':

Filter - ה-EEG האנושי כולל במידה רבה הספק אות בטווח תדרים של 1-30 Hz, התדר של מקורות רעש בתדר גבוה לדוגמא: רעש קו חשמל הוא רעש שנוצר על ידי רשת החשמל והוא מורכב מפסגות חדות של 50-60 Hz בהתאם למיקום הגיאוגרפי אשר עלול להשפיע בצורה ניכרת על תוצאות הפלט.

משמעות הדבר היא שעל ידי הפחתת עוצמת האות בתדרים שמעל ומתחת לטווח העניין (1-30 Hz), אנו יכולים להפחית רעש בתדרים גבוהים הנגרם לדוגמא ממקורות מתח חשמל וכדומה.

ה-**filter** עוזר לנו לנקות את הרעשים שמקורם אינם פיזיולוגיים.




Figure 12: לפני ואחרי הורדת התדרים הגבוהים של שלב א'

3.2.2. שלב ב':

ICA Independent component analysis - ניתוח רכיבים עצמאיים היא שיטת

עיבוד אותות להפרדה בין מקורות עצמאיים המעורבים באופן ליניארי במספר חיישנים. ע"י פירוק ליניארי ניתן לחשוף את המקורות הסטטיסטיים הבסיסיים של אותות מעורבים (לדוגמא: תזמורת), אות ה-EEG מורכב מתערובת של גלים שונים המופקים מקרקפת הראש וע"י פרוק למרכיבים אפשר להבחין באותות שאינם תוצאה של בחירת הנבדק (מצמוץ, דפיקות לב...).

ICA עשוי לסייע בזיהוי מקורות אותות שלא ניתן לזהות ברמת הנתונים, אלא ע"י פירוק האותות והשמטת הרעש אפשר לנקות אותות אלה.

עבור כל נבדק פירקנו את האותות ל-16 רכיבים וניסינו ע"י הרכיבים שקיבלנו וע"י זיהוי מקור האות מפלט הטופוגרפיה של הראש אשר מראה לנו את עוצמת האות ומקורו כמתואר באיור 13 לנסות להבין מהו מקור הרעש והאם הוא רלוונטי עבורנו לניתוח הנתונים, התהליך בוצע עבור כל נבדק בנפרד בצורה ידנית.

לדוגמא: כאשר זיהינו רעש חזק המגיע מהאזור הקידמי של הראש כמתואר באיור 13-ica001, שיערנו שמקור הרעש קשור במצמוצים של הנבדק ולכן ווידאנו שמקור הרעש הוא אכן המצמוצים ע"י הבחנה ויזואלית של נראות הרעש כמתואר באיור 14-ica001 כך יכלנו להוריד רעשים כגון מצמוצים דפיקות לב ועוד רעשים לא רצויים.

כפי שניתן לראות באיור 14 זיהנו את דפיקות הלב של הנחקר ולאחר הורדת רכיב הרעש של דפיקות הלב ניתן לראות את גלי ה-EEG ללא אותו רעש כמתואר באיור 15 ו-16.

ה-ica עוזר לנו לנקות את הרעשים שמקורם פיזיולוגיים.

ICA components




Figure 13: פירוק לרכיבים לפי פיזור טופוגרפי למקור הרעש ועוצמתו




Figure 14: פירוק האות לרכיבים, ניתן זיהוי בריבוע האדום את פעימות הלב של הנחקר




Figure 15: נראות האות לאחר הורדת רעש פעימות הלב




Figure 16: תקריב לשינויים מאיור 15

3.2.3. שלב ג':

כמוזכר לעיל מכשיר ההקלטה מחובר ביחד עם מחשב הניסוי ככה שעבור כל בחירה של הנבדק מופיע trigger על צייר הזמן של הגלים המוקלטים במחשב ה-EEG עבור כל נקודת עינין כזו (trigger) פירקנו את הנתונים ל- epochs על מנת לנסות ולהבין עבור כל בחירה של הנבדק את התהליך הקוגניטיבי המתרחש בראש, חילקנו את הנתונים לפי נקודות העניין (ביצע החלטה) ככה שעבור כל החלטה של הנבדק לקחנו את תחום הדגימה הרלוונטי מאותה החלטה כ-0.8 שניות לפני החלטה ו-0.2 שניות אחרי החלטה כמתואר באיור 17.




Figure 17: הצגת שלב ג'

3.2.4. שלב ד':

Baseline Correction - מכיוון שאותות ה-EEG הם אותות על ציר הזמן, לעיתים קרובות עשויות להיות לו סחיפות זמניות שאינן קשורות לשאלת הניסוי שלנו כגון עכבות פנימיות במערכת. מקורות פנימיים וחיצוניים שונים עלולים לגרום לסחיפות זמניות, המשתנות לאורך זמן, וגם על פני אלקטרודות. כדי להפחית את ההשפעה של סחיפות אלה ביצענו "נרמול לנתונים" בעיקרו של דבר, זה מורכב משימוש בפעילות EEG על פני תקופת בסיס (תקופת יחוס), כלומר לפני שמתרחש אירוע חיצוני, כדי לתקן את הפעילות על פני מרווח זמן הגירוי, כלומר מרגע הופעת ההצעה ועד קבלת ההחלטה. קיימות גישות שונות לתיקון קו הבסיס, כאשר הדרך המסורתית היא הפחתת הממוצע של תקופת קו הבסיס מכל נקודת מרווח זמן הגירוי. במילים אחרות, ערכי המתח הממוצע של כל אלקטרודה מחושבים בתוך מרווח זמן לפני הגירוי ואז ממוצע זה מופחת מהאותות בזמן הגירוי עצמו (כאשר הנבדק מקבל החלטה).

בניסוי שלנו לקחנו עבור כל epochs קו בסיס בין 0.8 שניות ל-0.2 שניות לפני שהתרחשה הבחירה וניקינו את הרעש מרגע הבחירה כמתואר באיור 18 ו-19.

נשים לב לסדר התהליך: Baseline Correction היא פעולה ליניארית מכיוון שאנו רק מחשבים את ממוצע הנקודות מתקופת הבסיס (שהיא פעולה ליניארית) ומחסירים ממוצע זה מכל נקודה בצורת הגל (שהיא גם פעולה ליניארית). משמעות הדבר היא שאפשר לבצע תיקון בסיסי לפני או אחרי כל תהליך ליניארי אחר ולקבל בדיוק את אותה תוצאה.

עם זאת, דחיית רכיב ב-ica היא תהליך לא ליניארי, כך שיייתכן שלא נקבל את אותה תוצאה על ידי ביצוע תיקון בסיסי לפני לעומת לאחר דחיית רכיב, הדבר תלוי באופי האלגוריתם שמפרק לרכיבים, אם האלגוריתם משתמש בסף מתח פשוט, אז באמת צריך לבצע תיקון בסיסי לפני דחיית רכיב עם זאת, האלגוריתמים של הממוצע הנע

בין שיא לשיא ופונקציית צעד אינם מושפעים מתיקון בסיסי, כך שניתן ליישם אלגוריתמים אלה לפני או אחרי תיקון הבסיס.

ה-Baseline Correction עוזר לנו לנקות את הרעשים שמקורם אינם פיזיולוגיים




Figure 18: נרמול הגלים לפי קו הבסיס שנמדד לפני ואחרי הניסוי




Figure 19: תקריב לשינויים מאיור 18

4. שיטת ניתוח פלט ה-EEG

עבור כל נבדק ביצענו את ניקוי הנתונים ושמרנו את בסיס הנתונים שלו מחדש בצורה הנקייה.

על מנת לנסות ולהעריך האם קיים שינוי בין שלבי הבחירה של הנבדק ביצענו מספר שלבים כהכנה לניתוח הסטטיסטי:

1. ממוצע בין הערוצים - עבור כל בחירה של הנבדק בין אם זה קבלה לבין דחייה בפרק הזמן שחילקנו את הדגימות (epochs) ביצענו ממוצע של 16 הערוצים ככה שקיבלנו גל אחיד עבור כל בחירה של כל נבדק.

2. הורדת ניסויים - מתוך הבנה שנבדק שאינו בחר באף הצעה וההצעה האחרונה נבחרה עבורו אוטומטית או נבדק שקיבל את ההצעה הראשונה, אינה תוכל להעיד על איזשהו תהליך קוגניטיבי לגיבוש החלטה! לכן מדגם בו הנחקר עבר את כל ההצעות או קיבל החלטה בהצעה הראשונה לא תחשב בניתוח הנתונים.

3. חיפוש נקודות מקסימום מוחלטות peak - כדי להעריך את הפעילות החשמלית עבור כל epochs חיפשנו את נקודות המקסימום המוחלטות בהנחה שאותם נקודות הם הפעילות החשמלית הנוצרת מ"ההחלטה" של הנבדק.

4. ERP (מאורעות הקשורים בפוטנציאל) - ה-ERP היא סידרה של שינויי מתח במערכת העצבים המרכזית הקשורים באופן קבוע בזמן לאירוע מוגדר, אירוע זה יכול להיות גירוי חושי, אירוע מוטורי או אירוע הכרתי, הרכיבים של הפוטנציאלים המעוררים הם ביטויים חיצוניים לתהליכים תוך מוחיים הם מחושבים על ידי מיצוע התגובה המוחית לאירועים חיצוניים או ע"י הזמן בין המאורע לבין הופעת הפיק (Absolute latency) במהלך ביצוע מטלה. ניתן להסתייע בפוטנציאלים המעוררים להבנה של תהליכים קוגניטיביים המעורבים בתפיסה, קשב, רגש, פעולה, זיכרון ועוד

Absolute latency: הוא מרווח הזמן בין הצגת הגירוי לנקודת הערך המקסימלי (שיא) של גלי ה-EEG. הוא מתבטא באלפיות שניות ומייצג את הזמן מרגע קבלת ההחלטה אצל הנבדק ועד רגע הבחירה (ה-trigger).

5. יצירת קבוצות להשוואה כהכנה למבחן הסטטיסטי (מבחן T) -

1. קבוצת ההצעות הראשונות.
 2. קבוצת ההצעות האחרונות (קבלת ההחלטה).
 3. קבוצת ההצעות האמצעית (יחסית לכמות ההצעות שהנבדק ראה).
 4. קבוצת ההצעות של הבחירה אחת לפני האחרונה (ההצעה לפני קבלת ההחלטה).
- החלוקה מורחבת בפרק התוצאות.

6. נרמול הזמן בין הופעת הפיק לבין המאורע - מאחר וקיים שוני בין הנבדקים עבור מרווח הזמן מרגע ה-peak ועד הופעת המאורע חישבנו עבור כל נבדק את ממוצע הזמן עבור כל ההצעות שראה. עבור כל מרווח הזמן מרגע ה-peak ועד הופעת המאורע חילקנו באותו הממוצע ככה שיצרנו את המרווח הזמן היחסי של הנבדק.

7. מבחני t-test - ביצענו מבחני t לכל 2 קבוצות. המבחן הינו מבחן t למדגמים תלויים. את המבחן ביצענו בצורה ממוחשבת בשפת python דרך ספריית scipy פונקציה `ttest_rel(x,y)`, x ו-y הם 2 קבוצות המדגם.

5. תוצאות

כחלק משלבי הניתוח אספנו מכל משתתף 4 דגימות בנקודות הזמן השונות לאורך הניסוי של הנבדק (בהתאם לטווח ההצעות שחקרנו $3 \leq bids\ range < 20$ כפי שניתן לראות 4.5) וחילקנו את הדגימות לקבוצות הבאות (לכל קבוצה נתנו שם קוד ב-python):

1. Start - קבוצת ההחלטות הראשונות של הנבדקים.

2. Median - קבוצת ההחלטות האמצעית של הנבדקים לפני קבלת ההחלטה, במידה וכמות ההחלטות זוגית נבחרה הבחירה לפי חלוקה ב-2 ועיגול כלפי מעלה.

3. One before - קבוצת ההחלטות אחת לפני קבלת ההחלטה, במידה ויש רק 3 החלטות אז: Median=One before.

4. End - קבוצת ההחלטות האחרונות בהכרח קבלה של הצעה.

תוצאות t-test למדגמים תלויים להשוואה בין הקבוצות:

start	vs	end:	pvalue=3.0420157399799234e-06
medean	vs	end:	pvalue=2.3319102510169605e-05
one_befor	vs	end:	pvalue=8.642406302776826e-06
start	vs	medean:	pvalue=0.7728036187144092
start	vs	one_befor:	pvalue=0.9319960490075054
one_befor	vs	medean:	pvalue=0.7932606942826905

Figure 20: תוצאות מבחן ה-t-test בהשוואה בין הקבוצות

לפי איור 20 ניתן לראות כי **לא קיים** הבדל מובהק סטטיסטית בין הקבוצות הבאות:

1. קבוצת ההחלטות הראשונה (דחייה) לבין קבוצת ההחלטות אחת לפני קבלת ההחלטה (דחייה).

2. קבוצת ההחלטות הראשונה (דחייה) קבוצת ההחלטות האמצעיות (דחייה) .

3. קבוצת ההחלטות האמצעיות (דחייה) וקבוצת ההחלטות אחת לפני (דחייה).

לפי איור 20 ניתן לראות כי **קיים** הבדל מובהק סטטיסטית בין הקבוצות הבאות:

1. קבוצת ההחלטות האחרונות (קבלה) לבין קבוצת ההחלטות אחת לפני קבלת ההחלטה (דחייה).

2. קבוצת ההחלטות האחרונות (קבלה) קבוצת ההחלטות הראשונה (דחייה).

3. קבוצת ההחלטות האחרונות (קבלה) קבוצת ההחלטות האמצעיות (דחייה).

על מנת לבחון את השערות המחקר ביצענו מספר ניתוחים על גבי הנתונים המעובדים. כל אחד מהניתוחים נועד לענות על השערה אחרת ועל כן נתייחס לכל השערה בנפרד:

1. **השערה**: קיים הבדל בפעילות המוחית לפני ואחרי זמן הבשלות המוחית לקבל החלטה הניתן לאבחון כההליך לגיבוש החלטה.

תוצאה: על פי המבחן הסטטיסטי ניתן לראות שלא קיים הבדל בין הקבוצות של דחיית ההצעה על כן ניתן להפריח את ההשערה הראשונה לפיה קיים הבדל בפעילות המוחית לפני ואחרי זמן הבשלות המוחית לקבל החלטה הניתן לאבחון כההליך לגיבוש החלטה.

2. **השערה**: קיים קשר בין הפתרון המתמטי של בעיית המזכירה הקלאסית ($1/e$) אל מול השלב בו המוח בשל לקבל החלטה.

תוצאה: ע"פ המדגם אולם מחישוב ממוצעי מיקומי הבחירה של הנבדקים תחת האילוץ ($19 > \text{number of decisions} > 3$) ניתן לראות שמיקום ההחלטה הוא 44.7% משמע אחרי 37% שזוהי הנקודה האופטימלית לראיית הצעות לפני הבחירה.

3. **השערה:** קיים הבדל בפעילות המוחית בקבלת החלטות תוך הבחנה בין קבלה לדחייה.

תוצאה: על פי איור 20 ניתן לראות כי אכן קיים הבדל מובהק סטטיסטית בין שלושת קבוצת ההחלטות הראשונות (התחלה, אמצע, אחת לפני האחרונה) (דחייה) לבין קבוצת ההחלטות האחרונה (קבלת ההצעה). ההבדל נמצא לכל אחד ואחד מהקבוצות בהשוואה לקבוצה האחרונה.

6. הנחות ומגבלות המחקר

1. נבדק שאינו בחר באף הצעה וההצעה האחרונה נבחרה עבורו אוטומטית, אינה תוכל להעיד על איזשהו תהליך קוגניטיבי לגיבוש החלטה! לכן מדגם בו הנחקר עבר את כל ההצעות לא תחשב בניתוח הנתונים.
2. נבדק שבחר בהצעה הראשונה מבלי לראות את שאר ההצעות, אינה תוכל להעיד על איזשהו תהליך קוגניטיבי לגיבוש החלטה! לכן מדגם בו הנחקר בחר בהצעה הראשונה לא תחשב בניתוח הנתונים.
3. לשם ניתוח הנתונים עבור כל החלטה של הנבדק חתכנו את רצף הנתונים כ-5 שניות לפני ההחלטה וכ-2 שניות אחרי ההחלטה.
4. על מנת לייצר לנבדק טווח ערכים שונה בין ניסוי לניסוי, בניסוי שלנו כל ניסוי זוגי הכפלנו את סקלת הערכים הלקוחים מהמארה שתבססנו עליו ב-10.
5. מגבלת זמן, מועד סיום הניסויים היה סמוך למועד הגשת הדוח המסכם על כן הסתפקנו בכמות הנבדקים הקיים.
6. מכשור, מכשירי ה-EEG לרוב באים עם תוספות ויכולות פונקציונליות אחרות המשפרים את טייב הדגימה כגון קסדת 64 ערוצים או שימוש ב-EOG ו-ECG המאפשרים ניקוי טוב יותר של הרעשים הפיזיולוגיים כגון מצמוצים ודפיקות לב.

7. דיון ומסקנות

צוות הפרויקט מכיל 2 סטודנטים, חלוקת המשימות התחלק בצורה אחידה מה שאפשר לנו לעסוק יחדיו בכל שלבי הפרויקט. ניתן לתאר את תהליך העבודה כשיתוף פעולה מלא תוך מחויבות אישי גבוהה של כל אחד מחברי הצוות.

במהלך המחקר הצוות היווה עבורנו סיור מוחות לתהליכים הרצויים, העלאת דילמות וסוגיות שונות כך ששנינו באנו לידי ביטוי לאורך הפרויקט תוך הפריה הדדית .

תוצאות המחקר כפי שניתחנו אותם לא הניבו פרי בניסיון למדל את המוח האנושי. ההשערה בה יש נקודה בזמן (כמובן לאחר מספר תצפיות) שלאחריה נראה שינוי בגל הופרכה דרך השוואה של 4 החלטות לאורך המשחק שבהן לא נמצא הבדל בין ההצעה הראשונה לאחת לפני האחרונה (שסביר להניח שהיא אחרי הנקודה בזמן שבא ניתן לראות בשלות לקבל החלטה). מצד שני מצאנו הבדל בין סוגי החלטות: דחייה וקבלה, כאשר השונו בין כל אחת מקבוצת ההשוואות אל מול קבוצת ההצעות האחרונה בה הנבדקים קיבלו החלטה מצאנו שקיים הבדל מובהק סטטיסטי במרווחי הזמן מרגע ההחלטה ועד לטריגר. במהלך הניתוח הגענו למספר צמתים בהם נדרשנו להחליט כיצד להמשיך לנתח, המחשבה והבחירה בכל פעם הייתה החלק הפורה ביותר בתהליך המחקר שביצענו, לדוגמה הוצאת חריגים באופן יזום כהכנה לניתוח הסטטיסטי, שחקן שקיבל את ההצעה לפני שלושת ההצעות הראשונות ושחקן שלא בחר בכלל והגיע להצעה ה-20 בלי לבחור בה.

לסיכום אנו נרגשים שהצלחנו להגיע למובהקות סטטיסטית והעבודה אינה הייתה לחינם, חלק אינטגרלי מההצלחה במחקר הייתה החניכה של המרצה האקדמי ד"ר ינון צוקרמן ביחד עם ד"ר דור מזרחי וד"ר אילן לאופר שהדריכו והנחו אותנו לאורך כל הפרויקט.

8. דיון נועם

אחד האתגרים ביותר מורכבים שהיו לי במהלך התואר היה הפרויקט המחקרי, כאשר האתגר המרכזי הוא ללמוד תחום שלא נפגשתי אתו בעבר, ללמוד את התהליכים הרצויים לעיבוד גלי ה-EEG, ללמוד את השיטות המתאימות לניתוח הסטטיסטי של הנתונים, בניית אפליקציה, תפעול מערכת ה-EEG וללמוד עוד דברים רבים במהלך הדרך. במהלך הפרויקט הבאתי לידי ביטוי כלים רבים אותם רכשתי בלימודי האקדמיים: ניתוחים סטטיסטיים, שיטות מחקר, ועוד קורסים רבים הקשורים בניתוח נתונים מה שהביא אותי לעמוד במטרת הפרויקט בהצלחה ולהביא עצמי לידי ביטוי על הצד הטוב ביותר תוך הקפדה על אחריות אישית, עמידה בזמנים ותכנון מקדים לצורך עמידה במתווה הפרויקט. לאורך כל הפרויקט ניתנה לנו האפשרות להביא עצמנו לידי ביטוי, להעלות דילמות וחלופות תוך ייעוץ והכוונה מקצועית של המנחה כולל בשלבים האחרונים של הניתוח הסטטיסטי, מה שתרם לסביבת העבודה לשמש כמקור ללמידה, התייעצות והפריה הדדית.

9. דיון

פרויקט מחקרי בבסיסו דורש ממך לעבוד קשה יותר על מנת לקבל תוצאות לנתונים השונים. פרויקט ראשון מסוגו המשלב את בעיית המזכירה הידועה בגרסאותיה השונות בתורת המשחקים עם קריאת גלי מוח בעזרת EEG. אני חושב שאם משום שהמשחקים היו יחסית קצרים וכמות ההצעות גם הייתה קטנה, מדגם של 20 הצעות למשתתף, כאשר בממוצע ההצעה נבחרה לפי מחצית ההצעות, היה אם נבצע את הניסוי שוב עם 100 הצעות לסיבוב ופחות סיבובים נוכל לקבל אבחנה טובה יותר בין ההחלטות שביצע שחקן מסוים במשחק אחד. אוכלוסיית המחקר נעה סביב אותו טווח גילאים וכולם היו עם מוטיבציה להרוויח כמה שיותר כסף מהניסוי, אני לא חושב שהאוכלוסייה פגעה בתוצאות הניסוי. השינוי שביצענו בטבלת ההצעות (כל עמודה שנייה בהכפלה פי 10) יכול היה להשפיע על התוצאות על מנת למנוע השפעה במשחק הדמה משתתף שיחק 2 סיבובים: אחד עם ואחד בלי הכפלה פי 10.

10. נספחים

10.1. נספח א' - טבלת הצעות מחיר

Table D1. The actual price offer sequences used in the experiment.

Round	1	2	3	4	5	6	7	8	9	10
Offer										
1	388	739	310	420	292	494	522	252	789	341
2	488	803	290	637	264	225	252	709	829	459
3	683	221	637	727	344	272	562	966	996	453
4	321	729	372	561	266	994	255	885	241	625
5	625	159	619	643	396	602	370	737	799	504
6	744	150	207	663	445	987	292	449	722	387
7	279	299	455	568	266	523	533	910	1088	250
8	848	818	400	636	241	683	237	250	876	308
9	276	585	251	422	370	1400	262	933	503	492
10	678	875	708	336	484	1574	343	491	650	455
11	408	130	452	414	264	1413	220	450	890	353
12	435	795	516	479	186	184	460	394	1264	588
13	679	481	420	332	578	1081	294	899	645	438
14	465	2	607	494	244	558	535	372	1740	408
15	393	525	410	546	189	273	297	505	1179	481
16	397	429	324	724	565	1182	452	608	250	467
17	588	62	214	411	271	305	284	827	840	418
18	358	459	480	267	235	661	436	712	272	273
19	644	748	463	357	350	785	581	838	449	554
20	495	374	617	733	373	89	197	541	105	553

Figure 21: טבלת הצעות המחיר הלקוחות מהספרות [2]

10.2. נספח ב' - תמונה גולמית של גלי ה-EEG




Figure 22: התוצר הגולמי המתקבל מאותות ה-EEG

10.3. נספח ג' - קטע הקוד הרשום ב-Python

GitHub link: <https://github.com/noam2641/Modeling-Human-Brain-ActivityIn-Secretary-Problem/blob/main/finalcode.ipynb>

```
In [2]: import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import mne
import mne.viz
from statistics import mean
from mne.preprocessing import peak_finder
import scipy.stats as stats
##%matplotlib inline
##%matplotlib qt
#raw=icadata[23]
import warnings
warnings.simplefilter('ignore')
```

```
In [6]: fname='C:/Users/user/OneDrive - Ariel University/קט/שנה ג/פרויקט/e.e.g apps/Standard-10-20-Cap16-Dor.locs'
montage= mne.channels.read_custom_montage(fname)
```

```
In [7]: %%capture
mapping = {'Channel 1':'Fp1', 'Channel 2':'F7', 'Channel 3':'T7', 'Channel 4':'P7', 'Channel 5':'Fp2', 'Channel 6':'F8', 'Channel 7':'T8', 'Channel 8':'P8', 'Channel 9':'F3', 'Channel 10':'C3', 'Channel 11':'P3', 'Channel 12':'O1', 'Channel 13':'O2', 'Channel 14':'Fz', 'Channel 15':'Cz', 'Channel 16':'Pz'}

Dir = 'C:/Users/user/OneDrive - Ariel University/קט/שנה ג/פרויקט/e.e.g apps/SECRETARY/'
tosaveica='C:/Users/user/OneDrive - Ariel University/קט/שנה ג/פרויקט/e.e.g apps/afterica'

data=list()
lebal=list()

for gdf_name in os.listdir(Dir):
    new_dir=Dir+gdf_name+'/secretary/gdf.GDF'
    data.append((mne.io.read_raw_gdf(new_dir,preload=True,stim_channel="auto", verbose=None).load_data()))
    mne.channels.rename_channels(data[-1].info, mapping, allow_duplicates=False, verbose=None)
    data[-1].set_montage(montage, match_case=True)
    data[-1].filter(l_freq=1., h_freq=30, fir_design="firwin", skip_by_annotation="edge")
```

```
In [6]: # clean ica component
cleandir='C:/Users/user/OneDrive - Ariel University/קט/שנה ג/פרויקט/e.e.g apps/afterica/'
Dir = 'C:/Users/user/OneDrive - Ariel University/קט/שנה ג/פרויקט/e.e.g apps/SECRETARY/'
def icafunc(raw):
    rawuse=raw.copy()
    ica = mne.preprocessing.ICA(n_components=16, max_iter='auto', random_state=97)
    rawuse.plot()
    ica.fit(rawuse)
    ica.plot_components()
    ica.plot_sources(rawuse, show_scrollbars=True)
    temp=None
    while True:
        print ("enter num ica to remove it: \nif no mor bad ica enter 77:")
        temp=int(input())
        if temp!=77:
            ica.exclude.append(temp)
            #ica.plot_components()
            ica.apply(rawuse)
            rawuse.plot()
            ica.plot_sources(rawuse, show_scrollbars=False)
        else: break
```



```

8]: %%capture
# read gdf file and apply previous ica that Saved in the previous step
cleandir='C:/Users/user/OneDrive - Ariel University/קט'ונות/שנה e.e.g apps/afterica/'
Dir = 'C:/Users/user/OneDrive - Ariel University/קט'ונות/שנה e.e.g apps/SECRETARY/'
icadata=list()
for fiffile in os.listdir(cleandir):
    new_dir_ica=cleandir+fiffile
    new_dir_raw=Dir+fiffile.split('-')[0]+'/secretary/gdf.GDF'
    raw= mne.io.read_raw_gdf(new_dir_raw,preload=True,stim_channel="auto", verbose=True).load_data()
    mne.channels.rename_channels(raw.info, mapping, allow_duplicates=False, verbose=None)
    raw.set_montage(montage, match_case=True)
    raw.filter(l_freq=1., h_freq=30, fir_design="firwin", skip_by_annotation="edge")
    ica= mne.preprocessing.read_ica(new_dir_ica)
    icadata.append(ica.apply(raw))

orderlist = list()
sinos=list()
for raw in icadata:
    all_events,all_event_id = mne.events_from_annotations(raw)
    metadata, events, event_id = mne.epochs.make_metadata(
        events=all_events, event_id=all_event_id,
        tmin=-0.8, tmax=0.2, sfreq=raw.info['sfreq'])
    epochs = mne.Epochs(raw, all_events ,all_event_id ,tmin=-0.8, tmax=0.2, picks='eeg',
        preload=True, baseline=(None,0),event_repeated='drop')

    ##### baseline corection #####
    interval = (-0.8, -0.5)
    epochs = epochs.apply_baseline(interval)

    ##### Creates a temporary list for each player How many bids did he see until he "making decision"
    ##### The list is a sum of series selections for example: a player who played 6 games in total and
    ##### for each game accepted the offer with the following bids: (13,6,9,14,5,8)
    ##### Then the temporary list(per_game) will look like this: (0,13,19,28,42,47,55)
    per_game=[0]
    count1=0
    seco='111'
    for event in np.array(metadata['event_name']):
        if (event=='333' ): #2=333
            count1+=1
            if (seco==event):
                per_game.append(per_game[-1]+count1-1)
                count1=1
            seco=event
    per_game.append(len(epochs['333'].events))

    ##### Creates a temporary list for each player
    ##### that for each index of the list is 1 of the 6 games that played by the same player
    games=list()
    for i in range(len(per_game)-1):
        games.append(epochs["333"].get_data()[per_game[i]:per_game[i+1],:,:])

    ##### Creates two lists as follows:
    ##### 1. The list "sinos" will contain all averages of 16 channels of the segments around the event "333" abo
    ##### before and 0.2 seconds after.
    ##### 2. The "orderist" is order list of the "sinos" list , each organ contains the number of bids the playe
    ##### he make a decision
    ##### For example orderlist = (3,4,6 ...)
    ##### the first 3 organ in the sinos will contain the events around the "333" of player X
    ##### So that the 3th event is the decision making
    ##### The next 4 organ in the sinos contained the events around the "333" of player Y so that the 6th index
    ##### would contain the event around the decision making
    ##### assumptions
    ##### A player who did not select any bids and the last bid was selected for him automatically, will not be a
    ##### to attest to any cognitive process for formulating of making decision so does an player who selected th
    ##### without see the other bids, will not be able to attest to any cognitive process for formulating of mak
    ##### So I cleared these situations from the data
    for onegame in games:
        if (np.array(onegame).shape[0]<3 or np.array(onegame).shape[0]==20 ):
            continue
        for clik in range(len(onegame)):
            if clik==len(onegame)-1:
                orderlist.append(len(onegame))
                sinos.append(np.mean(onegame[clik], axis=0) )
            else:
                sinos.append(np.mean(onegame[clik], axis=0) )

```

```
In [11]: ##### The percentage of amount of bids that the players saw before the making decision
print((np.mean(orderlist))/20)
```

0.4469827586206897


```
In [12]: %%capture
## Normalizes the time from the moment that the wave reached its peak to the event "333" by calculating the ave
## that time in all bids in that game until the decision was make. And a division of each of those times by the
## calculated
## I create 2 lists:
## 1."start" list will contain the normalized time for the first offer in all games
## 2."end" list will contain the normalized time for the last offer in which the player making ecision from a

index=0
start=list()
medean=list()
end=list()
one_befor=list()
for num_offer_to_decision in orderlist:
    sumbids=0
    for i in range(num_offer_to_decision):
        peak_locs, peak_mags = peak_finder(sinos[index+i])
        sumbids+=abs(triger_ind-peak_locs[np.argmax(peak_mags)])*0.00195312
    averag=sumbids/num_offer_to_decision
    peak_locs_start, peak_mags_start = peak_finder(sinos[index])
    peak_locs_medean, peak_mags_medean = peak_finder(sinos[index+round(num_offer_to_decision/2)-1])
    peak_locs_one_befor, peak_mags_one_befor = peak_finder(sinos[index+num_offer_to_decision-2])
    peak_locs_end, peak_mags_end = peak_finder(sinos[index+num_offer_to_decision-1])
    if len(peak_mags_start)<18 and len(peak_mags_end)<18 and len(peak_mags_medean)<18:
        start.append((abs(triger_ind-peak_locs_start[np.argmax(peak_mags_start)])*0.00195312)/averag)
        medean.append((abs(triger_ind-peak_locs_medean[np.argmax(peak_mags_medean)])*0.00195312)/averag)
        one_befor.append((abs(triger_ind-peak_locs_one_befor[np.argmax(peak_mags_one_befor)])*0.00195312)/averag)
        end.append((abs(triger_ind-peak_locs_end[np.argmax(peak_mags_end)-1])*0.00195312)/averag)
    index+=num_offer_to_decision
```

```
In [13]: peak_locs_start, peak_mags_start = peak_finder(sinos[99])
plt.plot(sinos[99],color="k")
for peak in peak_locs_start:
    plt.axvline(x=peak,color="gray")
plt.axvline(x=peak_locs_start[np.argmax(peak_mags_start)],color="b")
plt.axvline(x=triger_ind,color="r")
```

Found 5 significant peaks
<matplotlib.lines.Line2D at 0x1a363fb5af0>

Out[13]:



```
In [14]: ## Test t for dependent samples
## check if there is an internal difference within the group with itself
## if pvalue>0.05 it good
import scipy.stats as stats
print(stats.ttest_rel(start[:57],start[58:]))
print(stats.ttest_rel(medean[:57],medean[58:]))
print(stats.ttest_rel(one_befor[:57],one_befor[58:]))
print(stats.ttest_rel(end[:57],end[58:]))
```

```
Ttest_relResult(statistic=0.5770957079661627, pvalue=0.5661876885499234)
Ttest_relResult(statistic=0.06012991713879965, pvalue=0.9522662399088699)
Ttest_relResult(statistic=-0.8381667813573859, pvalue=0.4055003778694115)
Ttest_relResult(statistic=-0.8976620005469929, pvalue=0.3732089908850412)
```

```
In [27]: print("start      vs end:      pvalue="+str(stats.ttest_rel(start,end)[1]))
print("medean      vs end:      pvalue="+str(stats.ttest_rel(medean,end)[1]))
print("one_befor   vs end:      pvalue="+str(stats.ttest_rel(one_befor,end)[1]))
print("start      vs medean:    pvalue="+str(stats.ttest_rel(start,medean)[1]))## no
print("start      vs one_befor: pvalue="+str(stats.ttest_rel(start,one_befor)[1]))## no
print("one_befor   vs medean:    pvalue="+str(stats.ttest_rel(one_befor,medean)[1]))## no
```

```
start      vs end:      pvalue=3.0420157399799234e-06
medean      vs end:      pvalue=2.3319102510169605e-05
one_befor   vs end:      pvalue=8.642406302776826e-06
start      vs medean:    pvalue=0.7728036187144092
start      vs one_befor: pvalue=0.9319960490075054
one_befor   vs medean:    pvalue=0.7932606942826905
```

Figure 23: הקוד מכיל את קריאת הנתונים ניקוי הנתונים והניתוח הסטטיסטי

11. מקורות

- [1] Thomas, S.; Ferguson, A.; (Aug 1989); Who Solved the Secretary Problem? Institute of Mathematical Statistics: Statistical Science Vol. 4, No. 3 ,pp. 282-289.
- [2] Hsiao, C.; Kemp, S.; (2020); The effect of incentive structure on search in the secretary problem, Judgment and Decision Making, Vol. 15, No. 1, pp. 82-92.
- [3] Yajing, S.; Fali, L.; Duana, K.; Taoa, Q.; Cunbo, L.; Zehong, C.; Zhanga, Y.; Biswala, B.; Lig, P.; Yaoa, D.; (2019) Predicting individual decision-making responses based on single-trial EEG, NeuroImage Volume 206.
- [4] Mizrahi, D.; Laufer, I.; Zuckerman, I.; (2021) Topographic Analysis of Cognitive Load in Tacit Coordination Games Based on Electrophysiological Measurements. In Proceedings of the NeuroIS Retreat, Virtual Conference, Vienna, Austria, 1–3 June 2021.
- [5] "EEG>introduction"; http://www.medicine.mcgill.ca/physio/vlab/biomed_signals/EEG_n.htm; The McGill Physiology Virtual Lab.
- [6] Neil Bearden , J.; Murphy Ryan, O.; Rapoport, A.; (October 2005) ;A multi-attribute extension of the secretary problem: Theory and experiments; Journal of Mathematical Psychology; Volume 49, Issue 5, Pages 410-422.
- [7] Salma, N.; Mai, B.; Namuduri, K.; Mamun, R.; (17 November 2017); Using EEG Signal to Analyze IS Decision Making Cognitive Processes; Information Systems and Neuroscience pp 211–218

- [8] García-Hernández, P.; Alejandra, F.; Cortes, P; Hernández-González, M.; Sotelo-Tapia, C.; Angel Guevara, M.; (2021), Temporal division of the decision-making process An EEG study
- [9] Si, Y.; Wu, X.; Li, F.; Zhang, L.; Duan, K.; Li, P.; Song, L.; Jiang, Y.; Zhang, T.; Zhang, Y.; Chen, J.; Gao, S.; Biswal, B.; Yao, D.; Xu. P.; (2019), Different Decision-Making Responses Occupy Different Brain Networks for Information Processing: A Study Based on EEG and TMS, Cerebral Cortex, October 2019; 4119–4129.
- [10] Hsiao, Y. C; (2018); An experimental investigation of the secretary problem: factors affecting sequential search behavior Authors.
- [11] Alekseev, A.; Charness, G.; Gneezy, U.; (2017); Experimental methods: When and why contextual instructions are important, Journal of Economic Behavior & Organization, Volume 134, February 2017, Pages 48-59.
- [12] "Python Library for eeg: m.n.e", <https://mne.tools/stable/index.html>